

Proyecto - Etapa 2

Curso Web Semántica MISIS

Rubén Manrique & Nicolás Klopstock

Objetivo de la Etapa 2

En la primera etapa del proyecto, cada estudiante planteó un modelo conceptual a partir de las entidades, atributos y relaciones identificadas durante el proceso de enriquecimiento de los datos. En esta segunda etapa se realizará un **zoom sobre este modelo**, con el objetivo de revisarlo, formalizarlo y convertirlo en una ontología que pueda representar de manera explícita el conocimiento disponible en el dominio musical.

Para ello, cada estudiante deberá revisar las decisiones de modelamiento tomadas inicialmente, formalizar las clases, jerarquías, propiedades y restricciones utilizando RDF, RDFS y OWL, y transformar los datos consolidados durante la primera etapa en instancias de la ontología. Finalmente, deberán cargar el conocimiento generado en un endpoint RDF y comprobar, mediante consultas SPARQL, que el modelo construido permite responder preguntas relevantes sobre el dominio.


ETAPA 2

Cada estudiante deberá partir del modelo conceptual y del conjunto de datos consolidado entregados en la Etapa 1. El modelo conceptual podrá ser modificado durante esta etapa cuando se identifiquen problemas, ambigüedades o decisiones de diseño que puedan ser mejoradas. Los principales cambios realizados deberán ser documentados y justificados.

1. Revisión y formalización del modelo conceptual

A partir del modelo preliminar desarrollado en la Etapa 1, los estudiantes deberán definir formalmente los principales elementos de su dominio. Esto incluye la identificación y representación de:

- Clases y subclases.
- Propiedades de objeto.
- Propiedades de datos.
- Dominios y rangos de las propiedades.
- Jerarquías existentes entre las entidades del dominio.



- Instancias.

La ontología deberá representarse utilizando RDF y RDFS y deberá ser generada de forma reproducible mediante código. Se recomienda utilizar Python y librerías como RDFLib para la construcción y serialización del grafo (como se ha trabajado en talleres pasados).

El resultado deberá ser exportado en formato Turtle (.ttl).

2. Extensión del modelo utilizando OWL

Una vez formalizada la estructura básica de la ontología, cada estudiante deberá enriquecer el modelo utilizando los elementos de OWL que considere apropiados para representar las características y restricciones propias de su dominio.

Se deberán incorporar al menos **8 axiomas o restricciones OWL**, utilizando como mínimo **3 tipos diferentes de construcciones**. Por recordar algunas de las posibilidades de construcciones:

- Restricciones de cardinalidad.
- Clases equivalentes.
- Clases disjuntas.
- Propiedades inversas.
- Propiedades simétricas.
- Propiedades transitivas.
- Propiedades funcionales o funcionales inversas.
- Restricciones sobre valores o tipos de entidades relacionados.

Los elementos utilizados deberán responder a características reales del dominio modelado y no deberán incorporarse únicamente con el propósito de cumplir con el número mínimo solicitado.


Cada estudiante deberá explicar brevemente el significado de las restricciones incorporadas y justificar por qué son adecuadas para su modelo.

3. Competency Questions

Antes de poblar completamente la ontología, cada grupo deberá definir un conjunto de **8 competency questions**. Estas preguntas representan los tipos de consultas que una aplicación construida sobre el grafo de conocimiento debería ser capaz de responder.

Las preguntas deberán plantearse pensando en un posible producto o aplicación basada en el conocimiento modelado, por ejemplo: un sistema de exploración musical, un recomendador, una herramienta para analizar colaboraciones entre artistas o un sistema de consulta sobre la industria musical.

Las competency questions deberán utilizarse como mecanismo para revisar el modelo. Si una pregunta relevante no puede ser representada utilizando las clases y propiedades definidas, el estudiante deberá considerar modificar o extender su ontología.



4. Generación de instancias RDF

Utilizando los datos consolidados durante la Etapa 1, cada estudiante deberá generar automáticamente las instancias correspondientes a su ontología.

El proceso deberá realizarse mediante código y deberá transformar las entidades y relaciones presentes en los datasets consolidados a recursos RDF identificados mediante URIs.

Se deberán mantener separados el vocabulario de la ontología y sus instancias. Como resultado, se espera la generación de al menos los siguientes archivos:

- `ontology.ttl`: definición de clases, propiedades, jerarquías y restricciones.
- `instances.ttl`: instancias y relaciones generadas a partir de los datos de la Etapa 1.

Los identificadores utilizados deberán ser consistentes y reproducibles. No se deberán generar URIs diferentes para una misma entidad cada vez que se ejecute el código.

5. Carga y consulta de la ontología

La ontología y sus instancias deberán ser cargadas en **Apache Jena Fuseki** (como se ha hecho en los talleres).

Una vez cargado el grafo, cada grupo deberá implementar mediante SPARQL al menos **5 de las competency questions** definidas anteriormente.

Las consultas deberán demostrar el uso de la estructura del modelo y no limitarse únicamente a recuperar atributos individuales. Se espera que involucren relaciones entre diferentes entidades, jerarquías, filtros, agregaciones u otros elementos de SPARQL vistos durante el curso.

Para la entrega, **no es necesario entregar una instancia o servidor Fuseki configurado**. Los grupos deberán entregar todos los archivos necesarios para que los profesores puedan cargar y ejecutar el proyecto en una instalación de Fuseki. En particular, deberán incluir un archivo `configuracion.py` en el que se encuentren centralizados los parámetros utilizados para la conexión con Fuseki, tales como el nombre del dataset y las URLs de los endpoints de consulta y actualización.


Los profesores realizarán la carga de los archivos `ontology.ttl` e `instances.ttl` en Fuseki utilizando la configuración suministrada por cada grupo; de igual forma, van a ejecutar las consultas y deberá salir la misma respuesta que la documentada.

Bonus: extracción de conocimiento desde texto

De manera opcional, los grupos podrán enriquecer su grafo utilizando información obtenida desde **fuentes de texto no estructuradas** relacionadas con las entidades presentes en su dataset.

Por ejemplo, podrán identificar artículos, reseñas, críticas musicales, biografías u otras fuentes Web relacionadas con artistas, canciones o álbumes presentes en su grafo.

El proceso deberá incluir:



- Obtención automatizada de los textos mediante Web scraping, APIs u otros mecanismos.
- Selección de fragmentos o párrafos relevantes.
- Extracción automática de información adicional.
- Vinculación de la información obtenida con entidades existentes en la ontología.

La información extraída puede incluir, por ejemplo, géneros musicales mencionados en una crítica, influencias artísticas, colaboraciones, productores, instrumentos, lugares u otros conceptos que no se encontraran disponibles en las fuentes estructuradas utilizadas durante la primera etapa.


No será suficiente almacenar el texto completo. El objetivo del bonus es transformar información contenida en texto no estructurado en nuevas entidades, propiedades o relaciones dentro del grafo de conocimiento.

Consideraciones

- La ontología de esta etapa deberá construirse a partir del modelo conceptual desarrollado durante la Etapa 1. Los cambios realizados sobre dicho modelo deberán ser documentados y justificados.
- El uso de OWL deberá responder a necesidades reales de representación del dominio. No se evaluará positivamente la incorporación de restricciones o tipos de propiedades que no tengan una interpretación clara dentro del modelo.
- Las competency questions hacen parte del proceso de diseño de la ontología. Por esta razón, deberán ser formuladas antes de finalizar el modelo y utilizadas para evaluar si las clases y relaciones definidas permiten representar adecuadamente el conocimiento requerido.
- La generación de instancias deberá realizarse automáticamente a partir de los datasets obtenidos en la Etapa 1. No se espera la creación manual de instancias RDF.
- Todo el proceso deberá ser reproducible mediante el código entregado.
- Para efectos de esta etapa no se requiere realizar vinculación con ontologías externas o fuentes de Linked Data. Este proceso será abordado posteriormente en el curso.

Entregables

- Documento de máximo **6 páginas** que describa las principales decisiones de modelamiento, los cambios realizados sobre el modelo conceptual de la Etapa 1, las construcciones RDFS y OWL utilizadas, las competency questions propuestas y los principales problemas encontrados durante la implementación.
- Archivo `ontology.ttl` con la definición formal de la ontología.
- Código de generación de `instances.ttl`, archivo con las instancias generadas a partir de los datos consolidados durante la Etapa 1.



- Código fuente utilizado para transformar los datos de la Etapa 1 en RDF y generar los archivos Turtle. Se puede entregar mediante un repositorio de GitHub. El repositorio deberá ser público.
- Listado de las **8 competency questions** definidas por el grupo.
- Archivo con las consultas SPARQL correspondientes a por lo menos **5 competency questions**, junto con los resultados obtenidos al ejecutarlas sobre el endpoint.
- Evidencia de la ontología y sus instancias cargadas y funcionando correctamente en Apache Jena Fuseki.
- En caso de realizar el bonus, código correspondiente al proceso de extracción de información desde fuentes de texto y descripción de las nuevas entidades, propiedades o relaciones incorporadas al grafo.